

一、关于 Gibbs（基础知识）

参数空间 $\Phi = \{\Phi_1, \Phi_2, \dots, \Phi_p\}$ 有 p 个待估参数，以下是 Gibbs 的具体过程（参数估计值最后收敛）。

1. 初始化参数 $\Phi^{(0)} = \{\Phi_1^{(0)}, \Phi_2^{(0)}, \dots, \Phi_p^{(0)}\}$ ，给定观测值 Y 。

2. 在其他参数已知的条件下，抽取下一时刻的参数值：

$$\begin{aligned} \Phi_1^{(1)} &\sim p(\Phi_1 | \Phi_2^{(0)}, \Phi_3^{(0)}, \dots, \Phi_p^{(0)}; Y) \\ \Phi_2^{(1)} &\sim p(\Phi_2 | \Phi_1^{(1)}, \Phi_3^{(0)}, \dots, \Phi_p^{(0)}; Y) \\ (1) \quad \Phi_3^{(1)} &\sim p(\Phi_3 | \Phi_1^{(1)}, \Phi_2^{(1)}, \dots, \Phi_p^{(0)}; Y) \\ &\dots \\ \Phi_p^{(1)} &\sim p(\Phi_p | \Phi_1^{(1)}, \Phi_2^{(1)}, \dots, \Phi_{p-1}^{(1)}; Y) \end{aligned}$$

• • • • 得到 $\Phi^{(1)} = \{\Phi_1^{(1)}, \Phi_2^{(1)}, \dots, \Phi_p^{(1)}\}$

$$\begin{aligned} \Phi_1^{(2)} &\sim p(\Phi_1 | \Phi_2^{(1)}, \Phi_3^{(1)}, \dots, \Phi_p^{(1)}; Y) \\ \Phi_2^{(2)} &\sim p(\Phi_2 | \Phi_1^{(2)}, \Phi_3^{(1)}, \dots, \Phi_p^{(1)}; Y) \\ (2) \quad \Phi_3^{(2)} &\sim p(\Phi_3 | \Phi_1^{(2)}, \Phi_2^{(2)}, \dots, \Phi_p^{(1)}; Y) \\ &\dots \\ \Phi_p^{(2)} &\sim p(\Phi_p | \Phi_1^{(2)}, \Phi_2^{(2)}, \dots, \Phi_{p-1}^{(2)}; Y) \end{aligned}$$

• • • • 得到 $\Phi^{(2)} = \{\Phi_1^{(2)}, \Phi_2^{(2)}, \dots, \Phi_p^{(2)}\}$

(3) 以此类推，在 s 时刻有 $\Phi^{(s)} = \{\Phi_1^{(s)}, \Phi_2^{(s)}, \dots, \Phi_p^{(s)}\}$

(4) 由于开始的参数是随机初始化，和收敛时的数据存在一定差距，所以对于最后参数的估计，采用“退化”前 B 期的数据，最后的参数估计：

$$\hat{\Phi} = \frac{1}{S-B} \sum_{i=B+1}^S \Phi^{(i)}$$

简单记忆：尽可能利用“最新的已知参数”来抽取参数。

重点：后验概率分布的具体参数、具体分布求解(结合贝叶斯公式)，见(三)。

二、关于初始化

该过程是我结合代码最后进行理解。论文一开始提到 GARCH 模型，之后提到 SV 模型，而 SV 模型和 GARCH 模型主要差异在于最后的波动项。百度 GARCH 模型：如果方差用 ARMA 模型来表示，则 ARCH 模型的变形为 GARCH 模型，GARCH (p, q) 模型为：

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 + \beta_1 \sigma_{t-1}^2 + \dots + \beta_p \sigma_{t-p}^2$$

对应 GARCH (1, 1) 有：

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

可见论文中的 h_t 即是上式中的 σ_t^2 ，表示序列的波动。

下面叙述代码生成初始化参数和序列 $\{\ln h_t, \beta_t, \alpha_t, \sigma_t\}$ 的过程（在此说明，初始化参数这些参数将用于序列 $\ln h_t$ 更新，区别于 Gibbs 的初始化参数）。根据如下：

$$\begin{aligned} r_t &= \mu + a_t, a_t = \sqrt{h_t} \varepsilon_t \\ h_t &= \alpha_1 + \alpha_2 a_{t-1}^2 + \beta_1 h_{t-1} \end{aligned}$$

（1）构建 arima(0,0,0)模型(下面简称 model0)，其中含有时间序列的待估参数 μ 。

（2）在 model0 上加入 garch(1,1)作为方差(简称 model1),其中含有待估参数 α_1 、 α_2 、 β_1 。

（3）论文提供了交易数据的时间序列，而代码运用到的数据包含(close)列。首先对 close 进行如下操作：

$$rtn = \frac{close_t - close_{t-1}}{close_{t-1}}$$

（4）利用 rtn 数据来拟合 model1 模型的参数，得到：

$$\hat{\mu} = 0.006, \hat{\alpha}_1 = 0.001, \hat{\alpha}_2 = 0.031, \hat{\beta}_1 = 0.966$$

（5）对模型进行评估，estimate(model,rtn) 得到 $h_t = (rtn_t - prtn_t)^2$ ，其中 $prtn_t$ 为模型对该序列的预测值。对于原始序列，我们用到的是 $\ln h_t$ 。

（6）在下列 SV 模型中：

$$\begin{aligned} r_t &= \beta + a_t, a_t = \sqrt{h_t} \varepsilon_t \\ \ln h_t &= \alpha_1 + \alpha_2 \ln h_{t-1} + v_t \end{aligned}$$

在这里，我们把（4）得到的 $\hat{\mu}$ 作为 SV 模型的 β 估计值（初始值），而后通过 $\ln h_t$ 序列对

$\ln h_t = \alpha_1 + \alpha_2 \ln h_{t-1}$ 回归,得到 α_1 、 α_2 估计值（做为更新 $\ln h_t$ 的初始值），即：

$$\hat{\alpha}_1=-0.0505、\hat{\alpha}_2=0.9581$$

（1）最后再将 $\ln h_t$ 代入 $\ln h'_t = \hat{\alpha}_1 + \hat{\alpha}_2 \ln h_{t-1}$,计算序列 $(\ln h'_t - \ln h_t)^2$ 的方差得到 σ_v^2 的初始值（做为更新 $\ln h_t$ 的初始值） $\hat{\sigma}_v^2 = 0.0399$ 。

以上得到的初始化参数，在下面的 MCMC 过程中有运用到以上的参数，在这里做简单的铺垫。初始化参数表：

表 1 初始参数表

参数	初始值
β	0.006
α_1	-0.0505
α_2	0.9581
σ_v^2	0.0399

三、关于几个后验分布的推导

1. β 的后验分布参数:

$$\begin{aligned} r_t &= \beta + a_t, a_t = \sqrt{h_t} \varepsilon_t \\ \frac{r_t}{\sqrt{h_t}} &= \frac{\beta}{\sqrt{h_t}} + \frac{a_t}{\sqrt{h_t}} = \frac{\beta}{\sqrt{h_t}} + \varepsilon_t \\ \tilde{r}_t &= \beta x_t + \varepsilon_t, (\tilde{r}_t = \frac{r_t}{\sqrt{h_t}}, x_t = \frac{1}{\sqrt{h_t}}) \\ \tilde{r} &= \beta X + \varepsilon \end{aligned}$$

所以, 在 \tilde{r} 、 X 已知的条件下, β 的似然为:

$$\beta = \frac{\tilde{r} - \varepsilon}{X}$$

$$\therefore \text{Var}(\tilde{r}, X | \beta) = (X^T X)^{-1}, E(\tilde{r}, X | \beta) = \frac{\tilde{r}}{X}, p(\beta) \sim N(\beta_0, \sigma_{0,\beta}^2)$$

根据贝叶斯估计:

$$\begin{aligned} p(\beta | \tilde{r}, X) &\propto \exp\left\{-\frac{1}{2}\left[\frac{(\beta - \frac{\tilde{r}}{X})^2}{(X^T X)^{-1}}\right] - \frac{1}{2}\left[\frac{(\beta - \beta_0)^2}{\sigma_{0,\beta}^2}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\left[\frac{(\beta - \frac{\tilde{r}}{X})^2}{(X^T X)^{-1}} + \frac{(\beta - \beta_0)^2}{\sigma_{0,\beta}^2}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\left[\frac{(\beta - \frac{\tilde{r}}{X})^2 \sigma_{0,\beta}^2}{(X^T X)^{-1} \sigma_{0,\beta}^2} + \frac{(\beta - \beta_0)^2 (X^T X)^{-1}}{(X^T X)^{-1} \sigma_{0,\beta}^2}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\frac{(\beta - \frac{\tilde{r}}{X})^2 \sigma_{0,\beta}^2 + (\beta - \beta_0)^2 (X^T X)^{-1}}{(X^T X)^{-1} \sigma_{0,\beta}^2}\right\} \\ &= \exp\left\{-\frac{1}{2}\frac{[\sigma_{0,\beta}^2 + (X^T X)^{-1}]\beta^2 - 2[\frac{\tilde{r}}{X} \sigma_{0,\beta}^2 + \beta_0 (X^T X)^{-1}]\beta + [\sigma_{0,\beta}^2 (\frac{\tilde{r}}{X})^2 + (X^T X)^{-1} \beta_0^2]}{(X^T X)^{-1} \sigma_{0,\beta}^2}\right\} \\ &= \exp\left\{-\frac{1}{2}\frac{\beta^2 - 2\frac{\tilde{r}}{X} \frac{\sigma_{0,\beta}^2 + \beta_0 (X^T X)^{-1}}{\sigma_{0,\beta}^2 + (X^T X)^{-1}} \beta + B}{\frac{(X^T X)^{-1} \sigma_{0,\beta}^2}{\sigma_{0,\beta}^2 + (X^T X)^{-1}}}\right\}, (B \text{ 为常数}) \\ &= \exp\left\{-\frac{1}{2}\frac{\beta^2 - 2\frac{\tilde{r}}{X} \frac{\sigma_{0,\beta}^2 + \beta_0 (X^T X)^{-1}}{\sigma_{0,\beta}^2 + (X^T X)^{-1}} \beta + B}{\frac{(X^T X)^{-1} \sigma_{0,\beta}^2}{\sigma_{0,\beta}^2 + (X^T X)^{-1}}}\right\}, (B \text{ 为常数}) \end{aligned}$$

对于分母：

$$Var(\beta | \tilde{r}, X) = \frac{(X^T X)^{-1} \sigma_{0,\beta}^2}{\sigma_{0,\beta}^2 + (X^T X)^{-1}} = \left[\frac{\sigma_{0,\beta}^2 + (X^T X)^{-1}}{(X^T X)^{-1} \sigma_{0,\beta}^2} \right]^{-1} = (X^T X + \frac{1}{\sigma_{0,\beta}^2})^{-1}$$

对于分子：

$$\begin{aligned} & \beta^2 - 2 \frac{\tilde{r} \sigma_{0,\beta}^2 + (X^T X)^{-1} \beta_0}{\sigma_{0,\beta}^2 + (X^T X)^{-1}} \beta + B \\ &= [\beta - E(\beta | \tilde{r}, X)]^2 \\ E(\beta | \tilde{r}, X) &= \frac{\frac{\tilde{r}}{X} \sigma_{0,\beta}^2 + (X^T X)^{-1} \beta_0}{\sigma_{0,\beta}^2 + (X^T X)^{-1}} = \frac{[\frac{\tilde{r}}{X} \sigma_{0,\beta}^2 + (X^T X)^{-1} \beta_0] X^T X}{[\sigma_{0,\beta}^2 + (X^T X)^{-1}] X^T X} \\ &= \frac{\tilde{r} X^T \sigma_{0,\beta}^2 + \beta_0}{\sigma_{0,\beta}^2 X^T X + 1} = \frac{\tilde{r} X^T + \frac{\beta_0}{\sigma_{0,\beta}^2}}{X^T X + \frac{1}{\sigma_{0,\beta}^2}} = (X^T X + \frac{1}{\sigma_{0,\beta}^2})^{-1} (\tilde{r} X^T + \frac{\beta_0}{\sigma_{0,\beta}^2}) \end{aligned}$$

证毕。

注：在 β 的抽样中，和其他参数独立，只和不断更新的序列 $\ln h_t$ 、 \tilde{r} 、 β_0 、 $\sigma_{0,\beta}^2$ 有关。（给

定（ $\beta_0 = 0, \sigma_{0,\beta}^2 = 0.25$ ））

2. α 的后验分布参数：

$$\ln h_t = \alpha_1 + \alpha_2 \ln h_{t-1} + v_t$$

展开：

$$\begin{aligned} \ln h_t &= \alpha_1 + \alpha_2 \ln h_{t-1} + v_t \\ &\dots = \dots \\ \ln h_2 &= \alpha_1 + \alpha_2 \ln h_1 + v_2 \end{aligned}$$

令：

$$Z = (z_1, \dots, z_{n-1}), z_t = (1, \ln h_{t-1})^T, H_{-1} = (h_2, \dots, h_n)$$

矩阵形式：

$$\ln H_{-1} = \alpha Z + v$$

类比：

$$\tilde{r} = \beta X + \varepsilon \therefore \beta = \frac{\tilde{r} - \varepsilon}{X}$$

有：

$$\ln H_{-1} = \alpha Z + v \therefore \alpha = \frac{\ln H_{-1} - v}{Z}$$

$$Var(\ln H_{-1}, Z | \alpha) = \delta_v^2 (Z^T Z)^{-1}, E(\ln H_{-1}, Z | \alpha) = \frac{\ln H_{-1}}{Z}, p(\alpha) \sim N(\alpha_0, \Sigma_{0,\alpha})$$

根据贝叶斯估计：

$$\begin{aligned} p(a | \ln H_{-1}, Z) &\propto \exp\left\{-\frac{1}{2}\left[\frac{(\alpha - \frac{\ln H_{-1}}{Z})^T (\alpha - \frac{\ln H_{-1}}{Z})}{\sigma_v^2 (Z^T Z)^{-1}}\right] - \frac{1}{2}\left[\frac{(\alpha - \alpha_0)^T (\alpha - \alpha_0)}{\Sigma_{0,\alpha}}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\left[\frac{(\alpha - \frac{\ln H_{-1}}{Z})^T (\alpha - \frac{\ln H_{-1}}{Z})}{\sigma_v^2 (Z^T Z)^{-1}} + \frac{(\alpha - \alpha_0)^T (\alpha - \alpha_0)}{\Sigma_{0,\alpha}}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\left[\frac{(\alpha - \frac{\ln H_{-1}}{Z})^T (\alpha - \frac{\ln H_{-1}}{Z}) \Sigma_{0,\alpha} + (\alpha - \alpha_0)^T (\alpha - \alpha_0) \sigma_v^2 (Z^T Z)^{-1}}{\sigma_v^2 (Z^T Z)^{-1} \Sigma_{0,\alpha}}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\left[\frac{[\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}] \alpha^T \alpha - 2\alpha^T [\frac{\ln H_{-1}}{Z} \Sigma_{0,\alpha} + \alpha_0 \sigma_v^2 (Z^T Z)^{-1}] + [\Sigma_{0,\alpha} (\frac{\ln H_{-1}}{Z})^T (\frac{\ln H_{-1}}{Z}) + \sigma_v^2 (Z^T Z)^{-1} \alpha_0^T \alpha_0]}{\sigma_v^2 (Z^T Z)^{-1} \Sigma_{0,\alpha}}\right]\right\} \\ &= \exp\left\{-\frac{1}{2}\frac{\alpha^T \alpha - 2\alpha^T \frac{\frac{\ln H_{-1}}{Z} \Sigma_{0,\alpha} + \alpha_0 \sigma_v^2 (Z^T Z)^{-1}}{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}} + A}{\frac{\sigma_v^2 (Z^T Z)^{-1} \Sigma_{0,\alpha}}{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}}}\right\}, (A \text{ 为常数}) \end{aligned}$$

对于分母：

$$Var(a | \ln H_{-1}, Z) = \frac{\sigma_v^2 (Z^T Z)^{-1} \Sigma_{0,\alpha}}{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}} = \left[\frac{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}}{\sigma_v^2 (Z^T Z)^{-1} \Sigma_{0,\alpha}}\right]^{-1} = \left(\frac{1}{\sigma_v^2 (Z^T Z)^{-1}} + \Sigma_{0,\alpha}^{-1}\right)^{-1} = \left(\frac{Z^T Z}{\sigma_v^2} + \Sigma_{0,\alpha}^{-1}\right)^{-1}$$

对于分子：

$$\begin{aligned} &\alpha^T \alpha - 2\alpha^T \frac{\frac{\ln H_{-1}}{Z} \Sigma_{0,\alpha} + \alpha_0 \sigma_v^2 (Z^T Z)^{-1}}{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}} + A \\ &= [\alpha - E(\alpha | \ln H_{-1}, Z)]^T [\alpha - E(\alpha | \ln H_{-1}, Z)] \\ E(\alpha | \ln H_{-1}, Z) &= \frac{\frac{\ln H_{-1}}{Z} \Sigma_{0,\alpha} + \alpha_0 \sigma_v^2 (Z^T Z)^{-1}}{\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}} = \frac{[\frac{\ln H_{-1}}{Z} \Sigma_{0,\alpha} + \alpha_0 \sigma_v^2 (Z^T Z)^{-1}] \frac{Z^T Z}{\sigma_v^2}}{[\Sigma_{0,\alpha} + \sigma_v^2 (Z^T Z)^{-1}] \frac{Z^T Z}{\sigma_v^2}} \\ &= \frac{\frac{\ln H_{-1} Z^T \Sigma_{0,\alpha}}{\sigma_v^2} + \alpha_0}{\frac{\Sigma_{0,\alpha} Z^T Z}{\sigma_v^2} + 1} = \frac{\frac{\ln H_{-1} Z^T}{\sigma_v^2} + \frac{\alpha_0}{\Sigma_{0,\alpha}}}{\frac{Z^T Z}{\sigma_v^2} + \frac{1}{\Sigma_{0,\alpha}}} = \left(\frac{Z^T Z}{\sigma_v^2} + \frac{1}{\Sigma_{0,\alpha}}\right)^{-1} \left(\frac{Z^T \ln H_{-1}}{\sigma_v^2} + \frac{\alpha_0}{\Sigma_{0,\alpha}}\right) \end{aligned}$$

证毕。

注：在 α 的抽样中，和其他参数独立，只和不断更新的序列 $\ln h_t, \Sigma_{0,\alpha}, \alpha_0, \sigma_v^2$ （该值来

自 GARCH 初始化（二），给定（ $\Sigma_{0,\alpha} = [[0.4, 0], [0, 0.4]]$ 、 $\alpha_0 = [0, 0.2]$ ））。

3. σ_v^2 的后验概率:

通过:

$$\ln h_t = \alpha_1 + \alpha_2 \ln h_{t-1} + v_t$$

在 $\ln h_t$ 已知的条件下, 对 v_t 进行极大似然估计, 可得到 v_t 的似然:

$$\hat{v}_t = \frac{\sum_{i=1}^n (\ln h_t - \alpha_1 - \alpha_2 \ln h_{t-1})}{n-1} = \frac{SSR(\alpha)}{n-1}$$

$$\sigma_v^2 \sim \Gamma^{-1}(v_0 / 2, v_0 \sigma_{0,v}^2 / 2)$$

通过“共轭分布表”(附件 Conjugate prior.pdf) 可得:

图 1 共轭分布表

σ^2 (variance)	Inverse gamma	α, β [note 5]	$\alpha + \frac{n}{2}, \beta + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2}$
-----------------------	------------------	--------------------------	--

类推可得到:

$$\{1 / \sigma_v^2\} \sim \Gamma([v_0 + n - 1] / 2, [v_0 \sigma_{0,v}^2 + SSR(\alpha)] / 2)$$

注: 在 σ_v^2 的抽样中, 只和不断更新的序列 $\ln h_t$ 、 v_0 、 $\sigma_{0,v}^2$ 。(给定 $v_0=1$ 、 $\sigma_{0,v}^2=0.01$)

4. $\ln h_t$ 的后验分布

$$\because r_t = \beta + \sqrt{h_t} \varepsilon_t$$

$$\because r_t | \ln h_t \sim N(0, h_t)$$

$$\because \ln h_t = \alpha_1 + \alpha_2 \ln h_{t-1} + v_t$$

$$\therefore \ln h_t | \ln h_{t-1} \sim N(\alpha_1 + \alpha_2 \ln h_{t-1}, \sigma_v^2)$$

$$\because \ln h_{t+1} = \alpha_1 + \alpha_2 \ln h_t + v_{t+1}$$

$$\therefore \ln h_{t+1} | \ln h_t \sim N(\alpha_1 + \alpha_2 \ln h_t, \sigma_v^2)$$

$$\begin{aligned} p(\ln h_t | r_t, \beta, \ln h_{t-1}, \ln h_{t+1}, \alpha, \sigma_v^2) &\propto p(r_t, \ln h_{t-1}, \ln h_{t+1} | \ln h_t, \beta, \alpha, \sigma_v^2) p(\ln h_t) \\ &= p(r_t | \ln h_t, \beta) p(\ln h_{t-1} | \ln h_t, \alpha, \sigma_v^2) p(\ln h_{t+1} | \ln h_t, \alpha, \sigma_v^2) p(\ln h_t) \\ &= p(r_t | \ln h_t, \beta) [p(\ln h_{t-1} | \ln h_t, \alpha, \sigma_v^2) p(\ln h_{t+1} | \ln h_t, \alpha, \sigma_v^2)] p(\ln h_t) \quad (*) \\ &\propto p(r_t | \ln h_t, \beta) p(\ln h_t | \ln h_{t-1}, \alpha, \sigma_v^2) p(\ln h_{t+1} | \ln h_t, \alpha, \sigma_v^2) \\ &\propto p(r_t | \ln h_t, \beta) p(\ln h_t | \ln h_{t-1}, \alpha, \sigma_v^2) \end{aligned}$$

以上只对 $1 < t < n$ 有用, 而对于 $t=1$ and $t=n$ 边界有两种方法, 其一, 按下式, 不考虑 $\ln h_0$ 和 $\ln h_{n+1}$,

即边界概率去除了未知的值的影响:

$$p(\ln h_1 | r_1, \beta, \ln h_2, \alpha, \sigma_v^2) \propto p(r_1 | \ln h_1, \beta) p(\ln h_2 | \ln h_1, \alpha, \sigma_v^2) p(\ln h_1)$$

$$p(\ln h_n | r_n, \beta, \ln h_{n-1}, \alpha, \sigma_v^2) \propto p(r_n | \ln h_n, \beta) p(\ln h_n | \ln h_{n-1}, \alpha, \sigma_v^2)$$

其二, 考虑 $\ln h_0$ 和 $\ln h_{n+1}$, 但对他们进行“2步”估计(步长为2):

$$\ln \hat{h}_{n+1} = \alpha_1 + \alpha_2 (\alpha_1 + \alpha_2 \ln h_{n-1})$$

加入波动项并重写:

$$\begin{aligned} \because \ln h_t &= \alpha_1 + \alpha_2 \ln h_{t-1} + v_t \\ \therefore \ln h_t &= \alpha_1 \left(\frac{1 - \alpha_2}{1 - \alpha_2} \right) + \alpha_2 \ln h_{t-1} + v_t \\ \therefore \ln h_t - \frac{\alpha_1}{1 - \alpha_2} &= \alpha_2 \left(\ln h_{t-1} - \frac{\alpha_1}{1 - \alpha_2} \right) + v_t \\ \ln h_t - \eta &= \alpha_2 (\ln h_{t-1} - \eta) + v_t \end{aligned}$$

其中 $\eta = \alpha_1 / (1 - \alpha_2)$ 反向过程:

$$\ln h_t - \eta = \alpha_2 (\ln h_{t+1} - \eta) + v_t^*$$

得到:

$$\ln \hat{h}_0 = \alpha_2^2 (\ln h_2 - \eta) + \eta$$

在这种情况下, 便可得到代入(*)得到说有 $p(\ln h_t | r_t, \beta, \ln h_{t-1}, \ln h_{t+1}, \alpha, \sigma_v^2), 1 \leq t \leq n$,

由此解决了边界问题。

四、关于代码解析

1. Matlab 代码产生 (二) 中的初始化参数, 即表格(1)中参数数据, 及 $\ln h_t$ 原始序列。
2. 在 python 和 matlab 中复现 MCMC 过程。
3. Python 运行通过, 在 MCMC.ipynb 文件中。
4. 其中重点在 MH 算法 (<https://www.cnblogs.com/pinard/p/6638955.html>) 在求 $\ln h_t$ 中的运用。

5. 下面代码重点, 代码见文件 MCMC.ipynb 或 (<https://github.com/small-giu/Python with Finance/tree/master/MCMC>)

图 2 代码片段

```
# Metropolis sampling: ht
logh0 = alphas[i]*2*(loght[i]-alphas[i]/(1-alphas[i])) + alphas[i]/(1-alphas[i]) # ln h0, ite=alphas[i]/(1-alphas[i])
loghn1 = alphas[i]+alphas[i]*(alphas[i]+alphas[i]*loght[i-1]) # lnht+1
loghf1 = list(loght[1:]); loghf1.append(loghn1); loghf1 = np.array(loghf1) # log of one-step forward ht. [lnh1, lnh2, ..., lnht+1]
loghb1 = list(loght[:-1]); loghb1.insert(0, logh0); loghb1 = np.array(loghb1) # log of one-step backward ht. [lnh0, lnh1, lnh2, ..., lnht]
##### 重点 #####
# propose new ht, 下面来自于MH算法. stats.norm.pdf求概率值。
loghp = np.random.normal(loght, sigma_loghp)
# check log ratio of the posterior probability
# np.dot(np.array([[i, j] for i, j in zip(np.ones(n), list(loghb1))]), alphas.T) 难点 表示 lnht/lnht-1的均值
# stats.norm.pdf(x, 均值, 标准差)
logr = np.log(stats.norm.pdf(loghp, np.dot(np.array([[i, j] for i, j in zip(np.ones(n), list(loghb1))]), alphas.T), np.sqrt(Sigmavi))) + \
np.log(stats.norm.pdf(loghf1, np.dot(np.array([[i, j] for i, j in zip(np.ones(n), list(loghp))]), alphas.T), np.sqrt(Sigmavi))) - \
np.log(stats.norm.pdf(loght, np.dot(np.array([[i, j] for i, j in zip(np.ones(n), list(loghb1))]), alphas.T), np.sqrt(Sigmavi))) - \
np.log(stats.norm.pdf(loghf1, np.dot(np.array([[i, j] for i, j in zip(np.ones(n), list(loght))]), alphas.T), np.sqrt(Sigmavi))) - \
np.log(stats.norm.pdf(xtn-betai, 0, np.sqrt(np.exp(loght))))
# accept or not, 在这里修改了loght. 拒绝或接受
idxi = np.log(np.random.rand(n)) < logr
loght[idxi] = loghp[idxi]
#####
```